

Teoria da Probabilidade, Resumo da A2

jãopredo e artu

23/05/2025

Contents

1. Variáveis Aleatórias Contínuas	2
1.1. Definições	2
1.2. Propriedades da CDF e PDF	2
1.3. LOTUS (Law of The Unconscious Statistician)	3
1.4. Variância e Esperança	3
1.5. Propriedades da Esperança e Variância	3
2. Distribuições Contínuas	4
2.1. Distribuição Uniforme	4
2.1.1. Esperança	4
2.1.2. Variância	4
2.2. Distribuição Exponencial	5
2.2.1. Esperança	5
2.2.2. Variância	6
2.2.3. Perda de Memória	6
2.3. Distribuição Gamma	6
2.3.1. A função Gamma	6
2.3.2. A distribuição Gamma	7
2.3.2.1. Esperança	7
2.3.2.2. Variância	7
2.4. Distribuição Normal	7
2.4.1. Esperança	8
2.4.2. Variância	8
2.5. Taxa de Falhas	8
3. Variáveis Aleatórias Contínuas Bidimensionais	9
3.1. Função de Densidade Conjunta	9
3.1.1. Esperança, Variância e Desvio-Padrão	9
3.1.2. LOTUS 2	9
3.2. Distribuições Marginais e Condicionais	9
3.3. Covariância e Correlação	10
3.4. Esperança Condicional	10
3.5. Independência	11

1. Variáveis Aleatórias Contínuas

1.1. Definições

Definimos aqui o necessário sobre variáveis aleatórias contínuas para a compreensão dos conteúdos do teste:

Definição 1.1.1: (V.A Contínua)

Uma v.a $X : \Omega \rightarrow \mathbb{R}$ é dita contínua se e somente se sua CDF F_X for derivável

Definição 1.1.2: (Função de Distribuição - CDF)

A função de distribuição de uma v.a contínua X é dada por:

$$F_X(\varphi) = P(X \leq \varphi) \quad (1)$$

Definição 1.1.3: (Função de Densidade - PDF)

Calculamos a densidade de probabilidade calculando a probabilidade de X estar num intervalo, e dividimos pelo tamanho do intervalo:

$$\frac{P(X \in I = [\psi, \psi + \varepsilon])}{\|I\| = \varepsilon} = \frac{P(\psi \leq X \leq \psi + \varepsilon)}{\varepsilon} = \frac{F_X(\psi + \varepsilon) - F_X(\psi)}{\varepsilon} \quad (2)$$

Tomando o limite quando $\varepsilon \rightarrow 0$, obtemos a *função de densidade de probabilidade* PDF no ponto ψ :

$$\lim_{\varepsilon \rightarrow 0} \frac{F_X(\psi + \varepsilon) - F_X(\psi)}{\varepsilon} = F'_X(\psi) = f_X(\psi) \quad (3)$$

É importante notar que a PDF não é uma probabilidade, mas sim uma densidade de probabilidade. Veja:

$$P(X \in I) = P(a \leq X \leq b) = F_X(b) - F_X(a) \quad (4)$$

Usamos a PDF e o teorema fundamental do cálculo para calcular a probabilidade de X estar em um intervalo $I = [a, b]$:

$$P(X \in I) = F_X(b) - F_X(a) = \int_a^b f_X(\varphi) d\varphi \quad (5)$$

Logo a **a integral definida** da PDF é de fato uma probabilidade.

1.2. Propriedades da CDF e PDF

Dada uma v.a contínua X com PDF f_X e CDF F_X , é intuitivo que com $\varphi \rightarrow \infty$, $P(X \leq \varphi) = F_X(\varphi) \rightarrow 1$, e analogamente com $\varphi \rightarrow -\infty$, $P(X \leq \varphi) = F_X(\varphi) \rightarrow 0$. Então enunciamos as seguintes propriedades:

Propriedade 1.2.1.:

$$\begin{aligned} \lim_{\varphi \rightarrow \infty} F_X(\varphi) &= 1 \\ \lim_{\varphi \rightarrow -\infty} F_X(\varphi) &= 0 \end{aligned} \quad (6)$$

Logo, $F_X(\varphi)$ é uma função crescente, e $F_X(\varphi) \in [0, 1]$.

Propriedade 1.2.2.:

$$\begin{aligned} F_X(\varphi) &= \int_{-\infty}^{\varphi} f_X(\psi) d\psi \\ \int_{-\infty}^{\infty} f_X(\psi) d\psi &= 1 \end{aligned} \quad (7)$$

Propriedade 1.2.3.: Seja X uma v.a contínua com PDF f_X e CDF F_X , tome $h : \mathbb{R} \rightarrow \mathbb{R}$ crescente e $Y = g(X)$ com PDF e CDF f_Y, F_Y , respectivamente. Então:

$$f_Y(y) = \frac{f_X(\varphi)}{h'(\varphi)} \quad (8)$$

Com $\varphi = h^{-1}(y)$

Caso h seja decrescente:

$$f_Y(y) = -\frac{f_X(\varphi)}{h'(\varphi)} \quad (9)$$

Caso seja injetiva (pode ser crescente e decrescente em lugares diferentes):

$$f_Y(y) = \frac{f_X(\varphi)}{|h'(\varphi)|} \quad (10)$$

Caso seja uma função fudida quem nem injetiva é, mas pelo menos derivável, defina $\forall y \in \text{Im}(h)$:

$$I_y = \{x \in \mathbb{R} \mid h(x) = y\} \quad (11)$$

Contendo um número finito de elementos $x_1(y), \dots, x_{k(y)}(y)$. Então a densidade de Y é dada por:

$$f_Y(y) = \sum_{i=1}^{k(y)} \frac{f_X(x_i(y))}{|h'(x_i(y))|} \quad (12)$$

1.3. LOTUS (Law of The Unconscious Statistician)

Se X é uma v.a contínua com PDF $f_X(\varphi)$ e $g : \mathbb{R} \rightarrow \mathbb{R}$ é contínua, então a esperança de $Y = g(X)$ é dada por:

$$E(g(X)) = \int_{-\infty}^{\infty} g(\varphi) f_X(\varphi) d\varphi \quad (13)$$

1.4. Variância e Esperança

Definição 1.4.1: (Esperança)

Dada uma v.a contínua X com PDF $f_X(\varphi)$, a esperança de X é dada por:

$$E(X) = \int_{-\infty}^{\infty} \varphi f_X(\varphi) d\varphi \quad (14)$$

Definição 1.4.2: (Variância, Desvio-Padrão)

A variância de uma v.a contínua X com PDF $f_X(\varphi)$ e esperança $\mu = E(X)$ é dada por:

$$V(X) = E[(X - E(X))^2] = \int_{-\infty}^{\infty} [\varphi - \mu]^2 f_X(\varphi) d\varphi \quad (15)$$

O desvio padrão é:

$$\sigma(X) = \sqrt{V(X)} \quad (16)$$

1.5. Propriedades da Esperança e Variância

Dadas v.a's contínuas X, Y com PDF $f_X(\varphi), f_Y(\varphi)$ e $a, b \in \mathbb{R}$, temos:

Propriedade 1.5.1.:

$$\begin{aligned}
E(aX + b) &= aE(X) + b \\
E(X + Y) &= E(X) + E(Y) \\
V(aX + b) &= a^2V(X)
\end{aligned} \tag{17}$$

E caso X, Y sejam independentes:

$$\begin{aligned}
E(XY) &= E(X)E(Y) \\
V(X + Y) &= V(X) + V(Y)
\end{aligned} \tag{18}$$

Propriedade 1.5.2.: Podemos calcular a variância de X usando a esperança:

$$V(X) = E(X^2) - E(X)^2 \tag{19}$$

2. Distribuições Contínuas

2.1. Distribuição Uniforme

Uma v.a contínua X tem distribuição uniforme no intervalo $[a, b]$ se sua PDF for da forma:

$$f_X(\varphi) = \begin{cases} 0, & \text{se } \varphi < a \\ \frac{1}{b-a}, & \text{se } a \leq \varphi \leq b \end{cases} \tag{20}$$

Desta forma sua CDF é:

$$F_X(\varphi) = \begin{cases} 0, & \text{se } \varphi < a \\ \frac{\varphi-a}{b-a}, & \text{se } a \leq \varphi \leq b \\ 1, & \text{se } \varphi > b \end{cases} \tag{21}$$

O seguinte teorema é extremamente importante:

Teorema 2.1.1: (Universalidade da Uniforme)

Se X é uma v.a contínua com PDF f_X e CDF F_X , então $Y = F_X(X)$ é uma uniforme em $[0, 1]$, ou seja: $Y \sim U[0, 1]$

Demonstração:

$$F_Y(y) = P(Y \leq y) = P(F_X(X) \leq y) = P(X \leq F_X^{-1}(y)) = F_X(F_X^{-1}(y)) = y \tag{22}$$

Logo Y é uma uniforme em $[0, 1]$. □

2.1.1. Esperança

Com $X \sim U[a, b]$, temos

$$E(X) = \int_{-\infty}^{\infty} \varphi f_X(\varphi) d\varphi = \int_a^b \varphi \left(\frac{1}{b-a} \right) d\varphi = \frac{a+b}{2} \tag{23}$$

2.1.2. Variância

Com $X \sim U[a, b]$, temos:

$$\begin{aligned}
E(X^2) &= \int_{-\infty}^{\infty} \varphi^2 f_X(\varphi) d\varphi = \int_a^b \varphi^2 \left(\frac{1}{b-a} \right) d\varphi = \left(\frac{1}{b-a} \right) \int_a^b \varphi^2 d\varphi \\
&= \left(\frac{1}{b-a} \right) \left[\frac{\varphi^3}{3} \right]_a^b = \left(\frac{1}{b-a} \right) \left[\frac{b^3 - a^3}{3} \right] = \frac{b^2 + ab + a^2}{3}
\end{aligned} \tag{24}$$

E a variância fica:

$$V(X) = E(X^2) - E(X)^2 = \frac{b^2 + ab + a^2}{3} - \left(\frac{a+b}{2}\right)^2 = \frac{(b-a)^2}{12} \quad (25)$$

2.2. Distribuição Exponencial

Uma v.a contínua X tem distribuição exponencial se sua PDF for da forma:

$$f_X(\varphi) = \begin{cases} 0, & \text{se } \varphi < 0 \\ \lambda e^{-\lambda\varphi}, & \text{se } \varphi \geq 0 \end{cases} \quad (26)$$

$\lambda > 0$ é o parâmetro da distribuição. A CDF é dada por:

$$F_X(\varphi) = \begin{cases} 0, & \text{se } \varphi < 0 \\ 1 - e^{-\lambda\varphi}, & \text{se } \varphi \geq 0 \end{cases} \quad (27)$$




Figure 1: PDF e CDF Da Exponencial com $\lambda = 2$

Isto também é útil:

Proposição 2.2.1.: Se $X \sim \text{Expo}(\lambda)$, $Y = aX$, então $Y \sim \text{Expo}(\frac{\lambda}{a})$

Demonstração: Pela Propriedade 1.2.3., temos:

$$\begin{aligned} f_Y(y) &= \frac{f_X(\varphi)}{h'(\varphi)} \\ h'(\varphi) &= a \\ \varphi &= h^{-1}(y) = \frac{y}{a} \end{aligned} \quad (28)$$

Então:

$$\begin{aligned} f_Y(y) &= \frac{\lambda e^{-\lambda(\frac{y}{a})}}{a} = \left(\frac{\lambda}{a}\right) e^{-\lambda(\frac{y}{a})} \\ F_Y(y) &= 1 - e^{-\lambda(\frac{y}{a})} \end{aligned} \quad (29)$$

O que conclui a prova. □

Corolário 2.1.1.1: Se $X \sim \text{Expo}(\lambda)$, então $\lambda X \sim \text{Expo}(1)$

2.2.1. Esperança

Com $X \sim \text{Expo}(\lambda)$

$$E(X) = \int_{-\infty}^{\infty} \varphi f_X(\varphi) d\varphi = \int_0^{\infty} \varphi \lambda e^{-\lambda \varphi} d\varphi = \frac{1}{\lambda} \quad (30)$$

2.2.2. Variância

Com $X \sim \text{Expo}(\lambda)$, temos:

$$E(X^2) = \int_{-\infty}^{\infty} \varphi^2 f_X(\varphi) d\varphi = \int_0^{\infty} \varphi^2 \lambda e^{-\lambda \varphi} d\varphi = \frac{2}{\lambda^2} \quad (31)$$

E a variância fica:

$$V(X) = E(X^2) - E(X)^2 = \frac{2}{\lambda^2} - \left(\frac{1}{\lambda}\right)^2 = \frac{1}{\lambda^2} \quad (32)$$

2.2.3. Perda de Memória

Uma v.a X tem a propriedade de **perda de memória** se:

$$P(X > s + t \mid X > s) = P(X > t) \quad (33)$$

Isto é, a probabilidade de X ser maior que $s + t$, dado que já passou s , é a mesma que a probabilidade de X ser maior que t .

A distribuição exponencial é a única distribuição contínua que tem a propriedade de perda de memória.

2.3. Distribuição Gamma

2.3.1. A função Gamma

A função Γ é definida como:

$$\Gamma(\varphi) = \int_0^{\infty} t^{\varphi-1} e^{-t} dt \quad (34)$$

As propriedades abaixo serão muito úteis:

Propriedade 2.3.1.1.:

$$n \in \mathbb{N} \Rightarrow \Gamma(n) = (n-1)! \quad (35)$$

Propriedade 2.3.1.2.:

$$\Gamma(\varphi + 1) = \varphi \Gamma(\varphi), \forall \varphi > 0. \quad (36)$$

Alguns valores úteis de Γ são:

$$\begin{aligned} \Gamma\left(\frac{1}{2}\right) &= \sqrt{\pi} \\ \Gamma\left(\frac{3}{2}\right) &= \left(\frac{1}{2}\right)\sqrt{\pi} \\ \Gamma\left(\frac{5}{2}\right) &= \frac{3}{4}\sqrt{\pi} \\ \Gamma\left(\frac{7}{2}\right) &= \frac{15}{8}\sqrt{\pi} \\ \Gamma(1) &= 1 \\ \Gamma(2) &= 1 \\ \Gamma(3) &= 2 \\ \Gamma(4) &= 6 \\ \Gamma(5) &= 24 \\ &\vdots \end{aligned} \quad (37)$$

2.3.2. A distribuição Gamma

Uma variável aleatória X tem distribuição gamma com parâmetros $\alpha, \lambda > 0$ se sua PDF é dada por:

$$f_X(\varphi) = \begin{cases} 0, & \text{se } \varphi < 0 \\ \frac{\lambda^\alpha}{\Gamma(\alpha)} \varphi^{\alpha-1} e^{-\lambda\varphi}, & \text{se } \varphi \geq 0 \end{cases} \quad (38)$$

2.3.2.1. Esperança

A esperança de $Z \sim \Gamma(\alpha, \lambda)$ é:

$$E(Z) = \int_{-\infty}^{\infty} \varphi f_Z(\varphi) d\varphi = \int_0^{\infty} \varphi \frac{\lambda^\alpha}{\Gamma(\alpha)} \varphi^{\alpha-1} e^{-\lambda\varphi} d\varphi = \frac{1}{\Gamma(\alpha)} \int_0^{\infty} (\lambda\varphi)^\alpha e^{-\lambda\varphi} d\varphi \quad (39)$$

Fazendo $x = \lambda\varphi$, temos:

$$E(Z) = \frac{1}{\Gamma(\alpha)} \int_0^{\infty} x^\alpha e^{-x} \frac{dx}{\lambda} = \frac{1}{\lambda\Gamma(\alpha)} \Gamma(\alpha + 1) = \frac{\alpha}{\lambda} \quad (40)$$

2.3.2.2. Variância

Dada $Z \sim \Gamma(\alpha, \lambda)$:

$$\begin{aligned} E(Z^2) &= \frac{1}{\lambda\Gamma(\alpha)} \int_0^{\infty} (\lambda x)^{\alpha+1} e^{-\lambda x} dx = \left(\frac{1}{\lambda^2} \Gamma(\alpha) \right) \int_0^{\infty} x^{\alpha+1} e^{-x} dx \\ &= \left(\frac{1}{\lambda} \Gamma(\alpha) \right) \Gamma(\alpha + 2) = \frac{\alpha(\alpha + 1)}{\lambda^2} \end{aligned} \quad (41)$$

E a variância fica:

$$V(Z) = E(Z^2) - E(Z)^2 = \frac{\alpha(\alpha + 1)}{\lambda^2} - \left(\frac{\alpha}{\lambda} \right)^2 = \frac{\alpha}{\lambda^2} \quad (42)$$

Isso também pode ser útil:

Proposição 2.3.2.2.1.: Se $X \sim \Gamma(\alpha, \lambda)$ e $Z = \lambda X$, então $Z \sim \Gamma(\alpha, 1)$

Demonstração: Pela Propriedade 1.2.3., temos:

$$\begin{aligned} f_Z(z) &= \frac{f_X(\varphi)}{h'(\varphi)} \\ h'(\varphi) &= \lambda \\ \varphi &= h^{-1}(z) = \frac{z}{\lambda} \end{aligned} \quad (43)$$

Então:

$$f_Z(z) = \frac{\frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{z}{\lambda} \right)^{\alpha-1} e^{-\lambda \left(\frac{z}{\lambda} \right)}}{\lambda} = \left(\frac{1}{\Gamma(\alpha)} \right) z^{\alpha-1} e^{-z} \quad (44)$$

Assim $Z \sim \Gamma(\alpha, 1)$. □

2.4. Distribuição Normal

X v.a contínua tem distribuição normal com média μ e variância σ^2 se sua PDF é dada por:

$$f_X(\varphi) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(\varphi-\mu)^2}{2\sigma^2}} \quad (45)$$

Note que $f(\mu + a) = f(\mu - a)$, então a PDF é simétrica em torno de μ (a média).

A PROPOSIÇÃO ABAIXO É MUITO IMPORTANTE PARA RESOLVER PROBLEMS COM A NORMAL:

Proposição 2.4.1.: Se $X \sim N(\mu, \sigma^2)$, então $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$

Demonstração: Pela Propriedade 1.2.3., temos:

$$\begin{aligned} f_Z(z) &= \frac{f_X(\varphi)}{h'(\varphi)} \\ h'(\varphi) &= \frac{1}{\sigma} \\ \varphi &= h^{-1}(z) = \mu + \sigma z \end{aligned} \quad (46)$$

Então:

$$\begin{aligned} f_Z(z) &= \left(\frac{1}{\sigma\sqrt{2\pi}} \right) \frac{e^{-\frac{(\mu+\sigma z-\mu)^2}{2\sigma^2}}}{\frac{1}{\sigma}} \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} \end{aligned} \quad (47)$$

Logo $Z \sim N(0, 1)$. □

A Proposição 2.4.1. é muito útil para resolver problemas com uma tabela de valores da FDA de $N(0, 1)$.

2.4.1. Esperança

Com $X \sim N(\mu, \sigma^2)$, temos:

$$E(X) = \int_{-\infty}^{\infty} \varphi f_X(\varphi) d\varphi = \int_{-\infty}^{\infty} \varphi \left(\frac{1}{\sigma\sqrt{2\pi}} \right) e^{-\frac{(\varphi-\mu)^2}{2\sigma^2}} d\varphi = \mu \quad (48)$$

2.4.2. Variância

Com $X \sim N(\mu, \sigma^2)$, temos:

$$E(X^2) = \int_{-\infty}^{\infty} \varphi^2 f_X(\varphi) d\varphi = \int_{-\infty}^{\infty} \varphi^2 \left(\frac{1}{\sigma\sqrt{2\pi}} \right) e^{-\frac{(\varphi-\mu)^2}{2\sigma^2}} d\varphi = \mu^2 + \sigma^2 \quad (49)$$

Logo a variância fica:

$$V(X) = E(X^2) - E(X)^2 = \mu^2 + \sigma^2 - \mu^2 = \sigma^2 \quad (50)$$

2.5. Taxa de Falhas

Definição 2.5.1: Seja T o tempo de vida de um equipamento, ou seja o instante da sua primeira falha, cuja FDS é $F(t)$. A **confiabilidade** do equipamento é dada por:

$$R(t) = P(T > t) = 1 - F(t) \quad (51)$$

Definição 2.5.2: A **taxa média de falhas** de um equipamento num intervalo $[t, t + \Delta t]$, é a probabilidade de ele falhar nos próximos Δt , dado que ainda não falhou:

$$\begin{aligned} \text{TMF} &= \frac{P(T \leq t + \Delta t \mid T > t)}{\Delta} \Big|_t = \frac{P(T \leq t + \Delta t)}{\Delta t \cdot P(T > t)} = \frac{F(t + \Delta t) - F(t)}{\Delta t [1 - F(t)]} \\ &= \frac{R(t + \Delta t) - R(t)}{R(t) \cdot \Delta t} \end{aligned} \quad (52)$$

Quando $\Delta t \rightarrow 0$, obtemos a **taxa de falhas**:

$$\text{TF} = \lim_{\Delta t \rightarrow 0} \frac{R(t + \Delta t) - R(t)}{R(t) \cdot \Delta t} = \frac{-R'(t)}{R(t)} \quad (53)$$

3. Variáveis Aleatórias Contínuas Bidimensionais

3.1. Função de Densidade Conjunta

Definição 3.1.1: (Função de Densidade Conjunta)

Uma função de densidade conjunta $f(x, y)$ das variáveis X e Y é uma função com a seguinte propriedade:

$$P((X, Y) \in R) = \iint_R f(x, y) dA \quad (54)$$

Onde $R \subset \mathbb{R}^2$. Por conseguinte, f deve satisfazer:

$$\begin{aligned} f(x, y) &\geq 0, \forall (x, y) \in \mathbb{R}^2 \\ \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy &= 1 \end{aligned} \quad (55)$$

3.1.1. Esperança, Variância e Desvio-Padrão

Definição 3.1.1.1: (Esperança)

Dadas X, Y com densidade conjunta $f(x, y)$, a esperança de X é:

$$E(X) = \iint_{\mathbb{R}^2} x f(x, y) dA \quad (56)$$

Definição 3.1.1.2: (Variância, Desvio-Padrão)

A variância de X é análoga ao caso anterior:

$$V(X) = E(X^2) - E(X)^2 \quad (57)$$

O desvio padrão é:

$$\sigma(X) = \sqrt{V(X)} \quad (58)$$

3.1.2. LOTUS 2

Dadas X, Y com densidade conjunta $f(x, y)$, o valor esperado de uma função qualquer $g(X, Y)$ é:

$$E(g(X, Y)) = \iint_{\mathbb{R}^2} g(x, y) f(x, y) dA \quad (59)$$

Quando a densidade conjunta é constante em $S \subset \mathbb{R}^2$ e 0 fora de S , dizemos que $f(x, y)$ é uma função de densidade uniforme em S :

$$f(x, y) = \begin{cases} 0, & \text{se } (x, y) \notin S \\ \frac{1}{\text{Área}(S)}, & \text{se } (x, y) \in S \end{cases} \quad (60)$$

3.2. Distribuições Marginais e Condicionais

Lembrando o caso discreto, dadas X, Y v.a's discretas com densidade conjunta $p(x, y) = P(X = x \cap Y = y)$, temos os conceitos e covariância e correlação:

$$\begin{aligned} \text{Cov}(X, Y) &= E(XY) - E(X)E(Y) \\ \rho(X, Y) &= \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} \end{aligned} \quad (61)$$

Também temos as distribuições marginais e condicionais (Pelo teorema de Bayes e a Lei da Probabilidade Total):

$$\begin{aligned}
p_X(x) &= P(X = x) = \sum_y p(x, y) \\
p_Y(y) &= P(Y = y) = \sum_x p(x, y) \\
p_{X|Y}(x|y) &= P(X = x \mid Y = y) = \frac{p(x, y)}{p_Y(y)}
\end{aligned} \tag{62}$$

Com $f(x, y)$ sendo uma densidade conjunta, a diferença agora é a transição de $\sum \rightarrow \int$:

Definição 3.2.1: (Distribuição Marginal)

A distribuição marginal de X é dada por:

$$f_X(x) = \int_{-\infty}^{\infty} f(x, y) dy \tag{63}$$

Definição 3.2.2: (Distribuição Condicional)

A distribuição condicional de X dado Y é dada por:

$$f_{X|Y}(x|y) = \frac{f(x, y)}{f_Y(y)} \tag{64}$$

3.3. Covariância e Correlação

A Covariância e correlação são **análogas** ao caso discreto:

Definição 3.3.1: (Covariância)

A covariância de X e Y é dada por:

$$\text{Cov}(X, Y) = E(XY) - E(X)E(Y) \tag{65}$$

Definição 3.3.2: (Correlação)

A correlação de X e Y é dada por:

$$\rho(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma(X)\sigma(Y)} \tag{66}$$

3.4. Esperança Condicional

Isso é bem útil:

Definição 3.4.1: A esperança condicional de X na certeza de $Y = y$ é:

$$E(X \mid Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx \tag{67}$$

(As vezes denotado por $E[X|y]$).

Os teoremas da gênese também são úteis:

Teorema 3.4.1: (Lei de Adão)

\forall v.a's X, Y temos:

$$E(E(X|Y)) = E(X) \quad (68)$$

Demonstração: Trivial

□

Teorema 3.4.2: (Lei de Eva)

\forall v.a's X, Y , temos:

$$V(Y) = E(V(Y|X)) + V(E(Y|X)) \quad (69)$$

Demonstração: Trivial

□

3.5. Independência

As v.a's contínuas X e Y são ditas **independentes** se e somente se a densidade conjunta $f(x, y)$ for o produto das marginais:

$$f(x, y) = f_X(x)f_Y(y) \quad (70)$$